HW2 King County 房價預測：多元線性回歸分析報告

Oct 19, 2026 · 學號 7115056079

本報告以多元線性回歸預測美國 King County 房價，比較 5 種特徵選擇演算法後以簡約原則選出 11 個特徵，測試集達到 R^2 = 0.760、MAPE = 21.2%，95% 預測區間實際涵蓋率 94.4%。主程式為 `7115056079_hw2.ipynb`（同內容 `7115056079_hw2.py`）。

報告導覽

章節	內容	對應作業要求
資料集來源與研究脈絡	Kaggle 連結、21,613 筆、18 個特徵、研究脈絡	資料來源與連結
1. Business Understanding	商業問題、分析目標、成功標準	CRISP-DM
2. Data Understanding	房價分布、相關係數熱圖、全部 18 個特徵 vs 房價	CRISP-DM
3. Data Preparation	異常值、log 轉換、特徵工程、VIF、訓練／測試切分	CRISP-DM
4. Modeling	Baseline OLS、五種特徵選擇、k = 1–18 比較、主模型係數與預測公式	線性回歸、特徵選擇
5. Evaluation	各方法測試集比較、預測圖（95% CI／PI）、殘差與離群值診斷	模型評估、預測圖與區間
6. Deployment	模型存檔、predict_price() 範例	CRISP-DM
7. NotebookLM 研究摘要	網路解法四大做法、3 個研究來源	NotebookLM 研究摘要
8. 網路主流與更優解法比較	zipcode one-hot、Gradient Boosting 與主模型比較	主流或更優解法比較
9. GPT 輔助內容	與 Claude 的完整對話過程、AI 輔助範圍	GPT 對話過程
參考資料	14 筆文獻與網站	—

資料集來源與研究脈絡

項目	內容
資料集	House Sales in King County, USA（Kaggle, harlfoxem）
範圍	美國華盛頓州 King County（含西雅圖）2014/05–2015/05 房屋成交紀錄
筆數	21,613 筆，21 個欄位，無缺失值
目標變數	`price`（成交價，美元）
特徵數	扣除 `id`、`date`、`price` 後 18 個，符合作業 10–20 個特徵的要求
Kaggle 名次	本資料集為一般公開資料集，非競賽，無排行榜；改以預測圖與評估指標呈現成果

研究脈絡：King County 房價資料是 Kaggle 上最常被用來練習回歸的資料集之一 [1]。房價受面積、建材等級、地段等多重因素影響，適合用多元線性回歸檢驗各因素的邊際效果，並以預測區間量化估價不確定性。

1. Business Understanding

目標是做一個「可解釋」的房價估算工具：輸入房屋條件，輸出合理成交價與價格的可能範圍。買賣雙方、仲介與估價師都需要知道「哪些條件讓房價變高、高多少」，而不只是一個黑箱數字。本報告依 CRISP-DM 六階段流程 [2] 進行分析。

分析目標

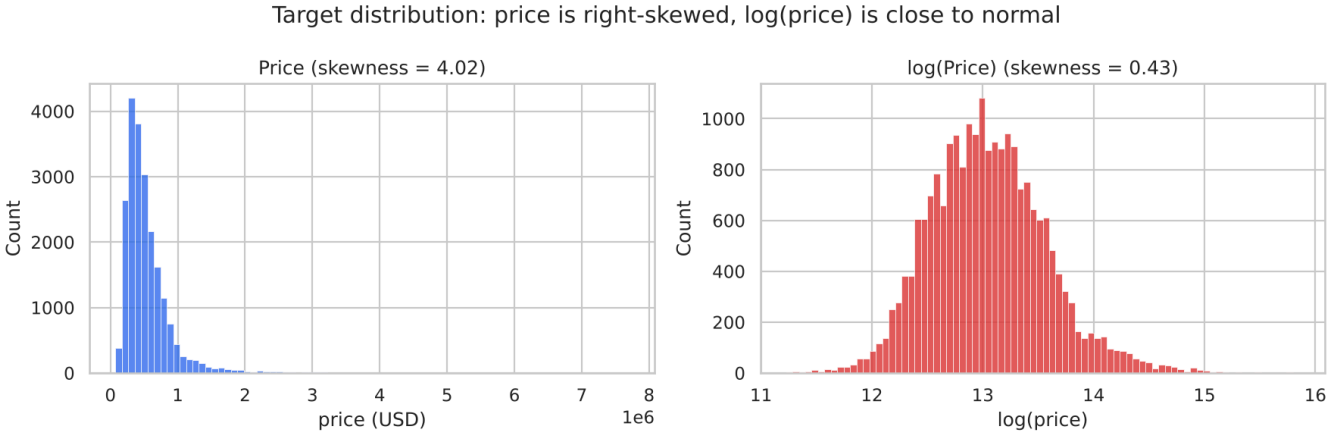
1. 以多元線性回歸預測房屋成交價 `price`。
2. 用特徵選擇找出關鍵影響因子，讓模型精簡且可解釋。
3. 以 R^2、Adjusted R^2、RMSE、MAE、MAPE 與 5-fold 交叉驗證評估模型，並提供 95% 信賴區間與預測區間。

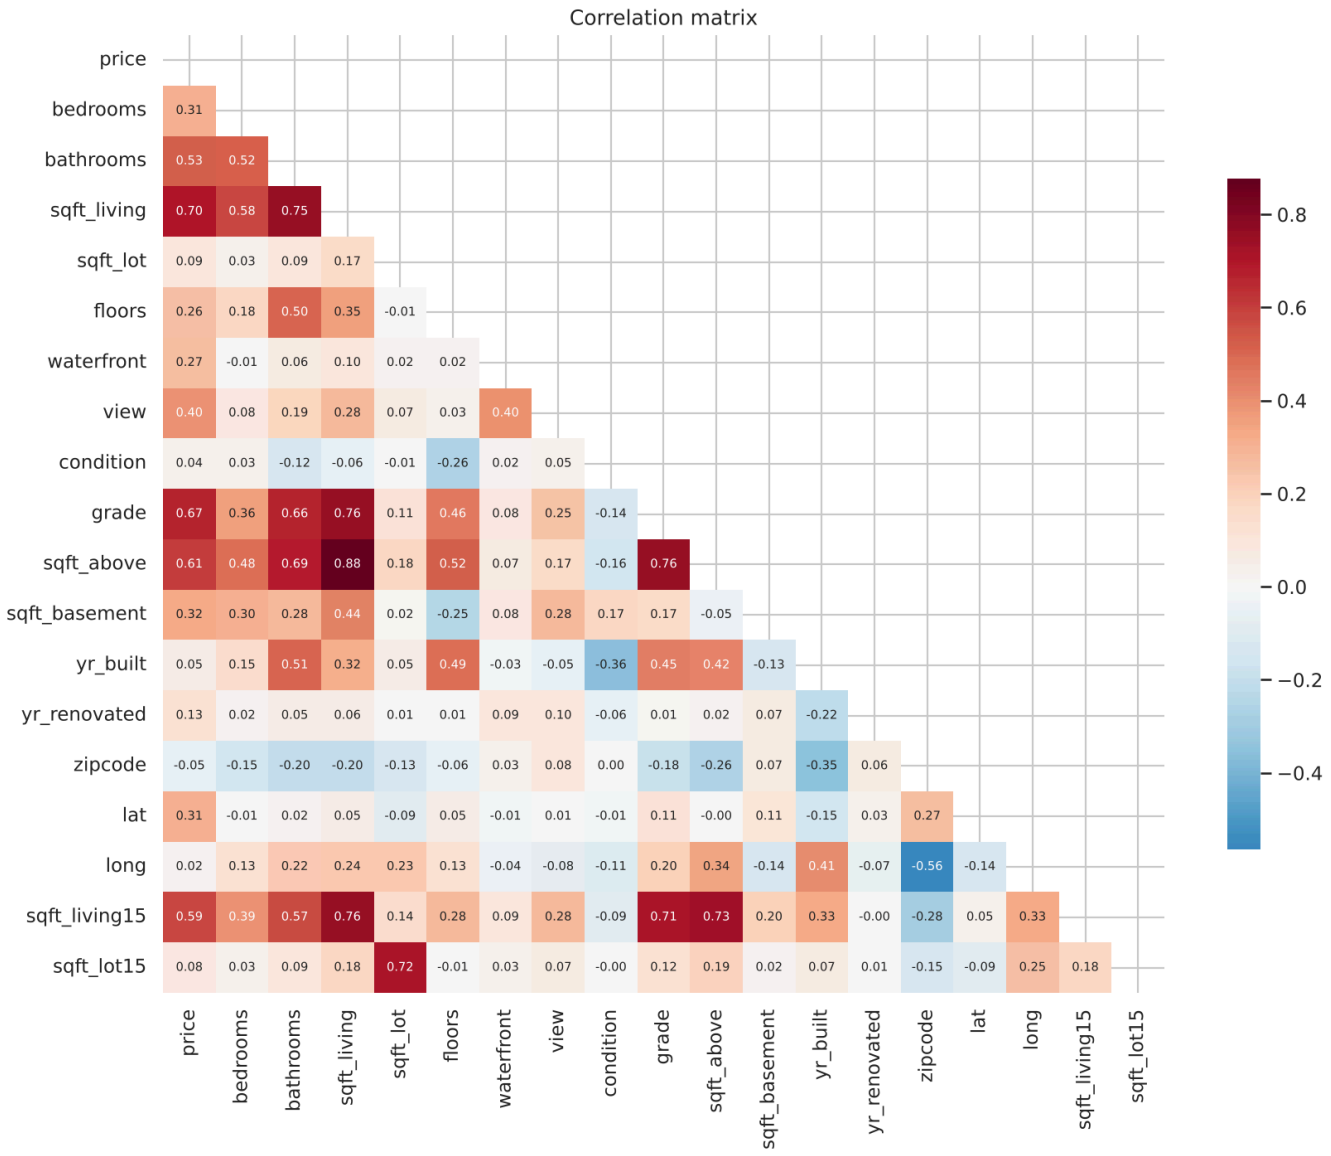
成功標準：測試集 R^2（log 價格）≥ 0.75，且 95% 預測區間的實際涵蓋率接近 95%。兩項皆達成（0.760、94.4%）。

2. Data Understanding

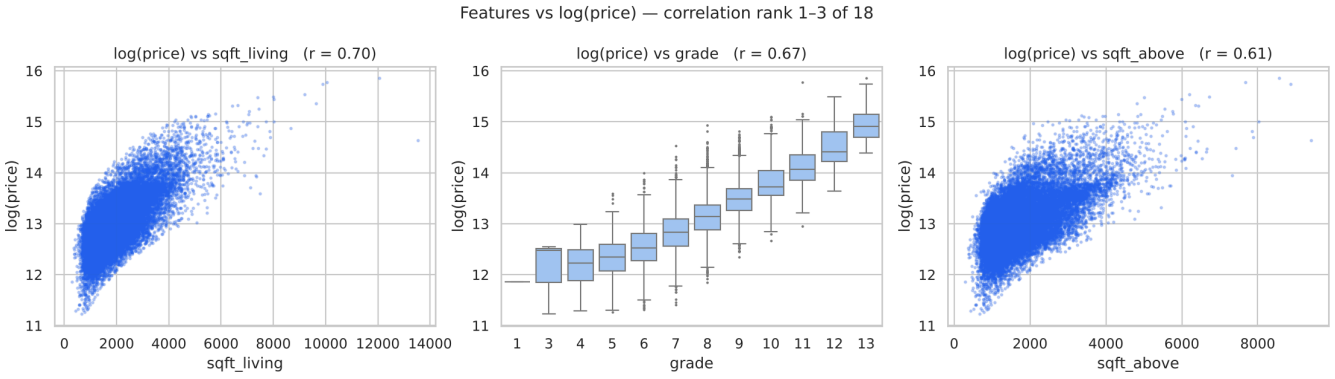
房價明顯右偏，取 log 後接近常態；與價格最相關的是居住面積（0.70）與建材等級（0.67）。資料無缺失值、無完全重複列。

類別	欄位
面積	sqft_living, sqft_lot, sqft_above, sqft_basement, sqft_living15, sqft_lot15
格局	bedrooms, bathrooms, floors
品質	grade（1–13 建材等級）, condition（1–5 屋況）, view（0–4 景觀）, waterfront（臨水 0/1）
年份	yr_built, yr_renovated
地點	zipcode, lat, long

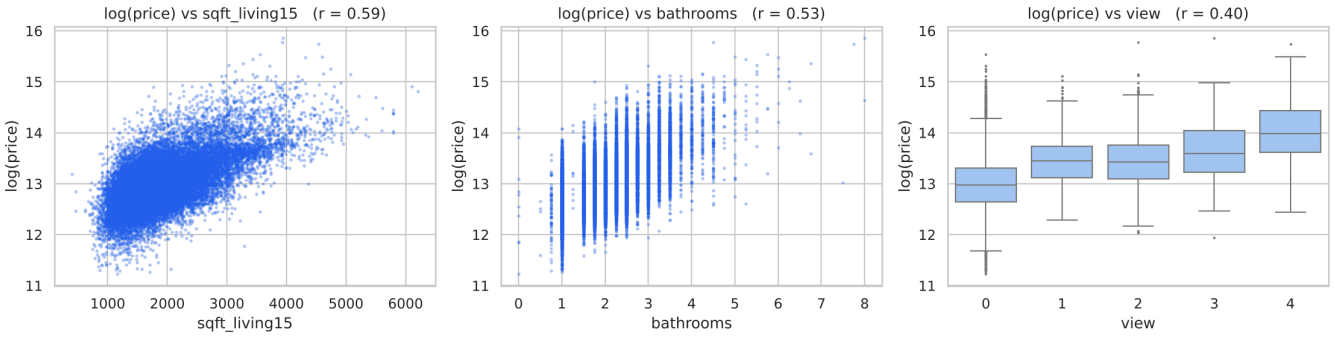




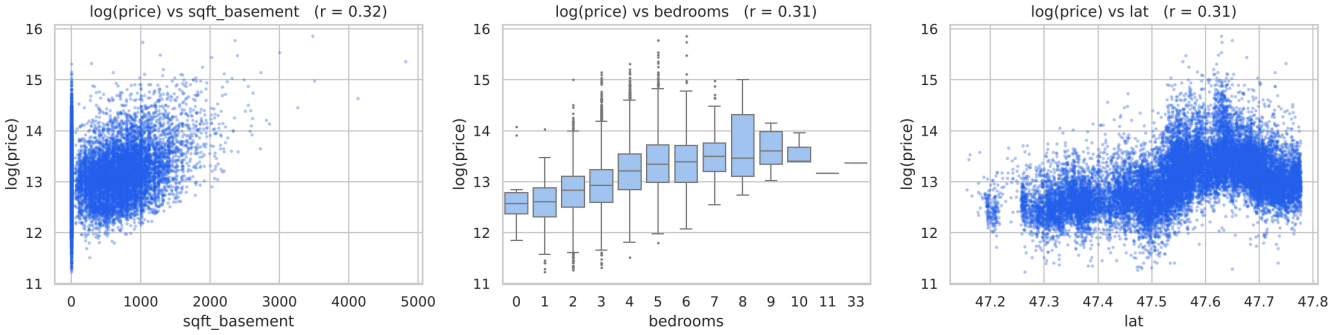
下列 18 張圖（每列 3 張）為全部 18 個特徵與 log(price) 的對比，依與房價的相關係數 |r| 由高到低排列。類別型特徵（≤ 15 種取值）以箱型圖呈現，連續型以散佈圖呈現；sqft_lot 與 sqft_lot15 極度右偏，x 軸改用 log 尺度。



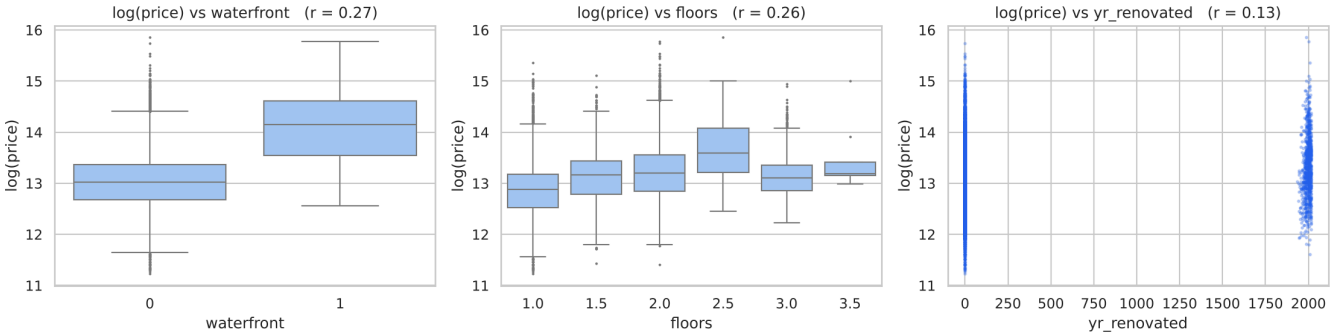
Features vs log(price) — correlation rank 4–6 of 18



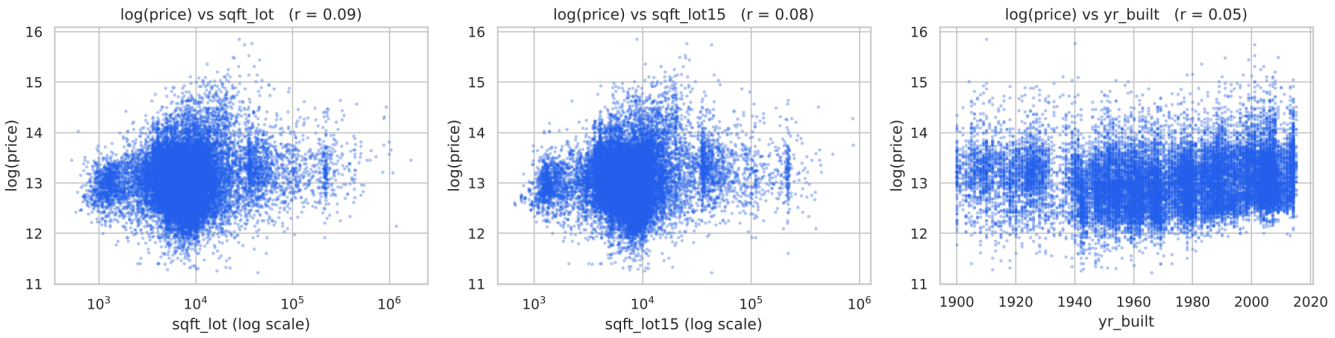
Features vs log(price) — correlation rank 7–9 of 18

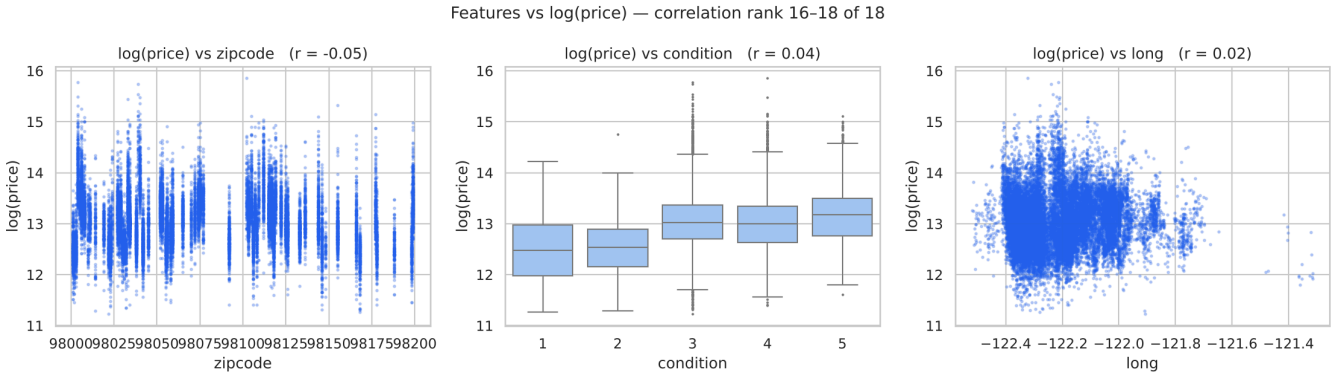


Features vs log(price) — correlation rank 10–12 of 18



Features vs log(price) — correlation rank 13–15 of 18





- **強正相關**：sqft_living、sqft_above、sqft_living15 與 log(price) 呈明顯線性趨勢；grade 每升一級，房價中位數穩定上升。
- **非線性關係**：lat 在 47.6 度附近（西雅圖市區與 Bellevue）最高；floors 以 2.5 層最高；bedrooms 超過 8 房後房價不再上升。
- **大量 0 值**：sqft_basement 與 yr_renovated 多數為 0，故在 Data Preparation 改為 has_basement、is_renovated 二元變數。
- **數值無意義**：zipcode 的數字大小與房價無關（r = -0.05），但不同郵遞區號的價位差異很大，表示應視為類別處理（第 8 節）。
- **單看弱、控制後強**：yr_built（r = 0.05）與 condition（r = 0.04）單看几乎無關，但在多元回歸中控制面積與等級後變得顯著（見 4.3 節）。

主要發現

- 與 price 相關係數最高：sqft_living 0.702、grade 0.667、sqft_above 0.606、sqft_living15 0.585、bathrooms 0.525。
- price 偏態係數約 4.0，log(price) 降到約 0.4，建模改用 log(price)。
- 177 個 id 重複，是同一間房子多次成交，屬合理紀錄，保留。
- sqft_living = sqft_above + sqft_basement，三者完全共線。
- bedrooms 有 33 房但面積僅約 1,600 sqft 的異常值，另有 0 房或 0 衛浴的紀錄，應為輸入錯誤。

3. Data Preparation

移除 17 筆異常值後剩 21,596 筆，建立 18 個候選特徵，依 80/20 切分為訓練集 17,276 筆、測試集 4,320 筆（random_state = 42）。所有特徵選擇只在訓練集上進行，避免資料洩漏。

處理	理由
刪除 33 房、0 房、0 衛浴共 17 筆	輸入錯誤或非住宅紀錄
price → log(price)	修正右偏，讓殘差更接近常態、變異數更穩定；係數可解讀為百分比變化

處理	理由
4 個面積欄位取 log	面積與價格是倍數關係，log-log 下更線性
刪除 sqft_above，sqft_basement → has_basement	解決完全共線
yr_built → house_age；yr_renovated → is_renovated	yr_renovated 約 96% 為 0，二元化較合理
date → sale_year、sale_month	捕捉時間趨勢與季節性
主模型不用 zipcode	70 個類別的數值大小無意義，地點改用 lat/long；one-hot 版本放在第 8 節比較

共線性檢查：18 個候選特徵的 VIF 最高為 log_sqft_lot 6.88 與 log_sqft_lot15 6.58，其餘皆 < 6，全部低於嚴重共線性門檻 10。

4. Modeling

以 OLS 多元線性回歸為基底，比較 5 種特徵選擇演算法在 k = 1–18 的表現。依簡約原則選定 k = 11，Forward SFS 與窮舉搜尋在 k = 11 選出的特徵完全相同。全部特徵選擇只用訓練集。

4.1 基底模型（Baseline OLS）

使用普通最小平方法（Ordinary Least Squares）多元線性回歸 [3]、全部 18 個特徵作為基準，建立特徵與 log(price) 之間的線性關係。

指標	數值
Train R^2 ／ Adjusted R^2	0.7754 ／ 0.7752
Test R^2	0.7621
整體 F 檢定	F = 3,310.8（df = 18, 17,257），p < 0.001
Test RMSE ／ MAE	$177,852 ／ $109,297

F 檢定拒絕「所有係數皆為 0」，模型整體顯著。問題是 18 個特徵是否都需要，以下用特徵選擇回答。

4.2 特徵選擇演算法（Feature Selection Algorithms）

每種演算法都產生「k = 1…18 時要用哪 k 個特徵」：

1. **Lasso（L1 正則化）**：L1 懲罰項把不重要的係數壓到 0 [4]；沿正則化路徑，依係數「離開 0」的先後排序。

2. **Forward SFS（前向序列特徵選擇）**：從 0 個特徵開始，每次加入讓 5-fold CV R^2 提升最多的特徵 [3]。
3. **RFE（遞迴特徵消除）**：從全部特徵開始，反覆移除標準化係數絕對值最小的特徵 [5]。
4. **ElasticNet（彈性網路，l1_ratio = 0.5）**：結合 L1 與 L2 懲罰，共線性高時較穩定 [6]；排序方式同 Lasso。
5. **Exhaustive Search（窮舉搜尋）**：測試全部 $2^{18} - 1 = 262{,}143$ 種子集，找出每個 k 下訓練 SSE 最小的組合 [3]。

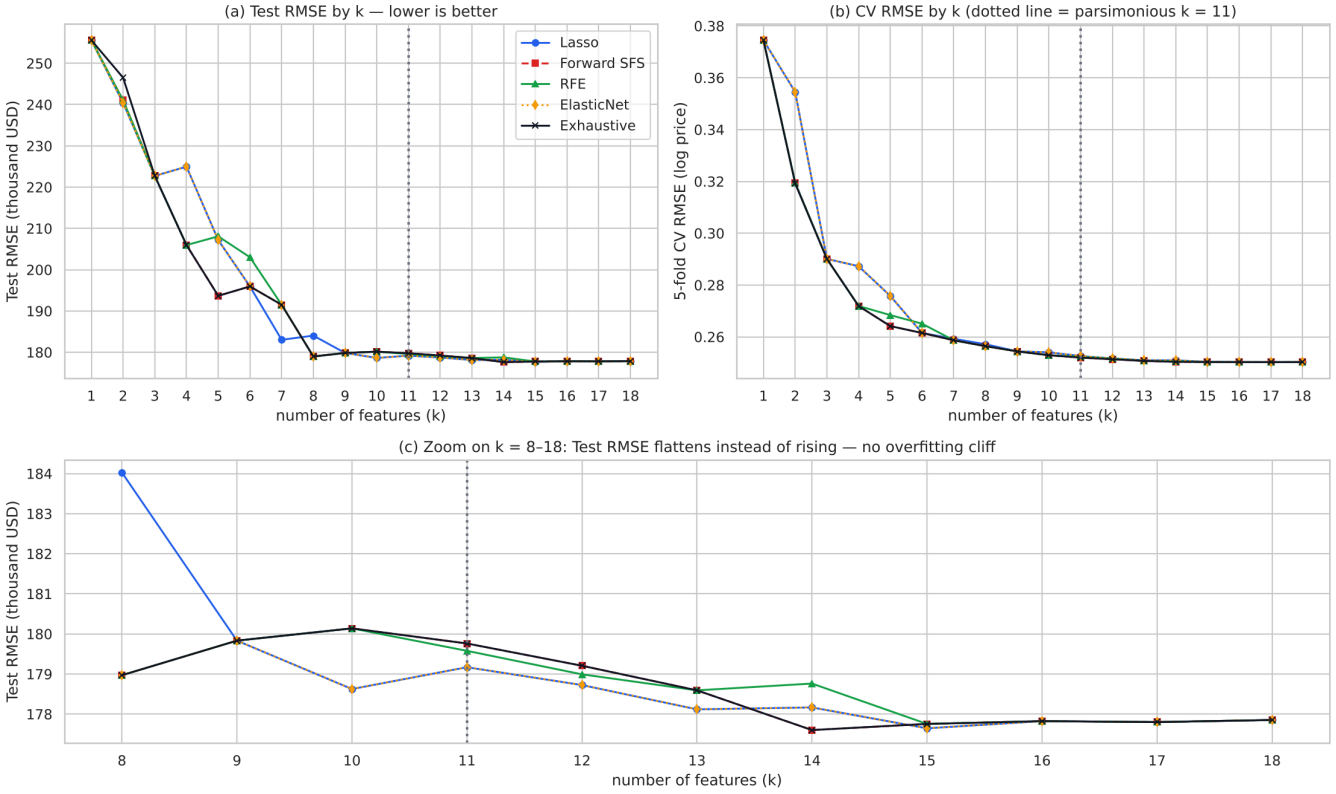
以 scikit-learn [7] 的 LassoCV（alpha = 0.00037）與 ElasticNetCV（alpha = 0.00074）以交叉驗證選最佳懲罰時都保留全部 18 個特徵，因為樣本數遠大於特徵數，懲罰很小。因此改用「進入路徑的順序」來排序特徵。

特徵	Lasso	Forward SFS	RFE	ElasticNet	Exhaustive
grade	1	1	1	1	1
log_sqft_living	2	3	3	2	2
lat	3	2	2	3	2
house_age	6	4	4	6	4
view	5	5	7	5	5
log_sqft_living15	4	6	5	4	6
bathrooms	9	7	6	7	7
waterfront	7	8	8	8	8
condition	8	9	9	9	9
floors	11	10	10	11	10
sale_year	12	11	13	12	11
log_sqft_lot15	13	12	12	13	12
bedrooms	15	13	11	15	13
is_renovated	10	14	15	10	14
log_sqft_lot	16	15	14	16	15
has_basement	14	16	16	14	16
sale_month	17	17	17	17	17
long	18	18	18	18	18

數字是該特徵在第幾個 k 被選入。五種方法都把 grade 排第 1、sale_month 與 long 排最後。窮舉搜尋的結果不是層層嵌套的：k = 1 最佳是 grade，但 k = 2 最佳反而是 log_sqft_living + lat，這是逐步法無法發現的。

4.3 特徵數量與模型評估（k = 1–18）

每種方法、每個 k 都重新配適 OLS，計算訓練集 5-fold CV RMSE（用來選 k）與測試集 RMSE（用來報告）。

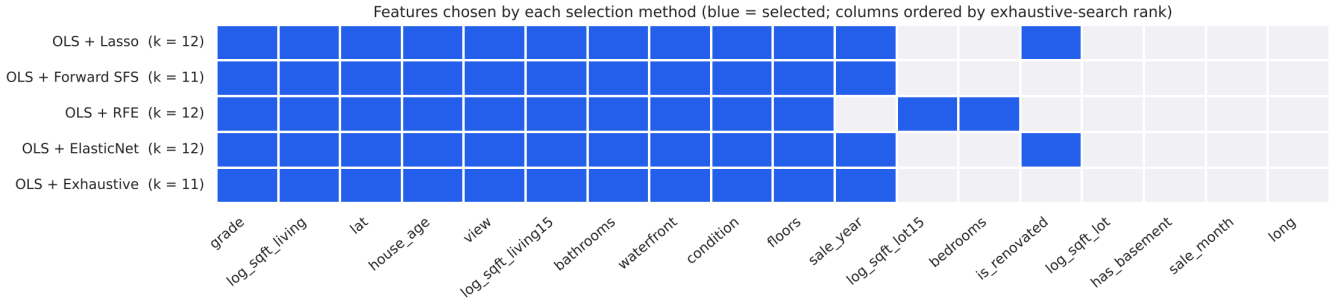


簡約性分析（Parsimony Analysis）

- **甜點區（Sweet Spot）**：五種方法的 CV RMSE 都在 k = 17 最低（0.2502），Test RMSE 則在 k = 14（Forward SFS 與 Exhaustive，$177,601）或 k = 15（Lasso 與 ElasticNet，$177,644）最低。曲線從 k ≈ 9 開始走平。
- **簡約選擇 k = 11**：取 CV RMSE 與最小值差距 < 0.002 的最小 k（0.2520 vs 0.2502）。代價是 Test RMSE 比甜點多 $2,160（+1.2%），Test R^2 從 0.7621 降到 0.7595，換得少用 7 個特徵。
- **選入的 11 個特徵**：grade、lat、log_sqft_living、house_age、view、log_sqft_living15、bathrooms、waterfront、condition、floors、sale_year。排除 bedrooms、log_sqft_lot、log_sqft_lot15、has_basement、is_renovated、long、sale_month。
- **過擬合警告（Overfitting Cliff）**：沒有出現（見上圖 (c)）。k = 11 之後繼續加特徵，Test RMSE 只在 $2,160 範圍內小幅下降，沒有回升。該網站的資料只有 50 筆，在 k = 5 就過擬合；本資料訓練集有 17,276 筆，遠大於 18 個特徵，參數估計很穩定。
- **共線性（VIF）**：11 個特徵的 VIF 最高為 log_sqft_living 4.14，其餘 < 3.1，皆低於 5。

4.4 不同特徵選擇方法的影響

五種方法都用同一個簡約規則各自選 k（CV RMSE 與該方法最小值差距 < 0.002 的最小 k），再用選出的特徵配適 OLS。結果：Forward SFS 與 Exhaustive 選 11 個且完全相同；Lasso 與 ElasticNet 選 12 個且完全相同；RFE 選 12 個但組合不同。



方法	k	與主模型的差異	CV RMSE（log）	Train Adj R^2	F 統計量	VIF 最大值
Baseline OLS	18	全部特徵	0.2502	0.7752	3,311	6.88
OLS + Lasso	12	+ is_renovated	0.2516	0.7726	4,892	4.14
OLS + Forward SFS（主模型）	**11**	—	**0.2520**	**0.7720**	**5,317**	**4.14**
OLS + RFE	12	+ log_sqft_lot15、+ bedrooms、− sale_year	0.2516	0.7726	4,891	5.26
OLS + ElasticNet	12	+ is_renovated	0.2516	0.7726	4,892	4.14
OLS + Exhaustive	11	與主模型相同	0.2520	0.7720	5,317	4.14

- **核心特徵不受方法影響**：grade、log_sqft_living、lat、house_age、view、log_sqft_living15、bathrooms、waterfront、condition、floors 這 10 個，五種方法全都選入。
- **差異只在邊際特徵**：方法之間只在第 11–12 個特徵不同，CV RMSE 差距最多 0.0004。
- **方法特性造成的差異**：Lasso 與 ElasticNet 沿正則化路徑較早納入 is_renovated；RFE 依標準化係數大小刪除，保留了與面積相關的 bedrooms、log_sqft_lot15，故 VIF 較高（5.26）。
- **主模型**：各方法準確度幾乎相同，取特徵最少的 Forward SFS（= Exhaustive）的 11 個特徵，F 統計量最高、VIF 最低。測試集上的比較見 5.1 節。

4.5 主模型（OLS + Forward SFS，11 個特徵）的 OLS 係數

n = 17,276，R^2 = 0.7721，Adjusted R^2 = 0.7720，整體 F = 5,317.3（df = 11, 17,264，p < 0.001），11 個係數的 p-value 皆 < 0.001。信賴區間與預測區間依公式 [3] 自行計算：

- **95% 信賴區間（CI，平均反應）**：$\hat{y}_0 \pm t(0.025, n-p) \times \hat{\sigma} \times \sqrt{x_0^T (X^T X)^{-1} x_0}$
- **95% 預測區間（PI，個別房屋）**：$\hat{y}_0 \pm t(0.025, n-p) \times \hat{\sigma} \times \sqrt{1 + x_0^T (X^T X)^{-1} x_0}$

- PI 多了「單筆觀測本身的誤差」項（根號內的 1），所以一定比 CI 寬。

特徵	係數	95% CI	解讀
waterfront	0.425	[0.378, 0.472]	臨水房價格高約 53%
log_sqft_living	0.277	[0.259, 0.295]	居住面積 +1%，房價 +0.28%
log_sqft_living15	0.219	[0.200, 0.237]	鄰居平均面積 +1%，房價 +0.22%
grade	0.174	[0.169, 0.180]	建材等級 +1，房價 +19.0%
lat	1.346	[1.317, 1.374]	往北 0.1 度（約 11 km），房價 +14.4%
bathrooms	0.069	[0.061, 0.078]	多 1 間衛浴，+7.2%
floors	0.065	[0.056, 0.074]	多 1 層，+6.7%
view	0.062	[0.056, 0.067]	景觀 +1 級，+6.4%
condition	0.062	[0.055, 0.068]	屋況 +1 級，+6.3%
sale_year	0.047	[0.039, 0.055]	2015 年成交比 2014 年高 4.8%
house_age	0.0039	[0.0037, 0.0040]	屋齡 +10 年，+3.9%（控制其他條件後，老房多在成熟地段）

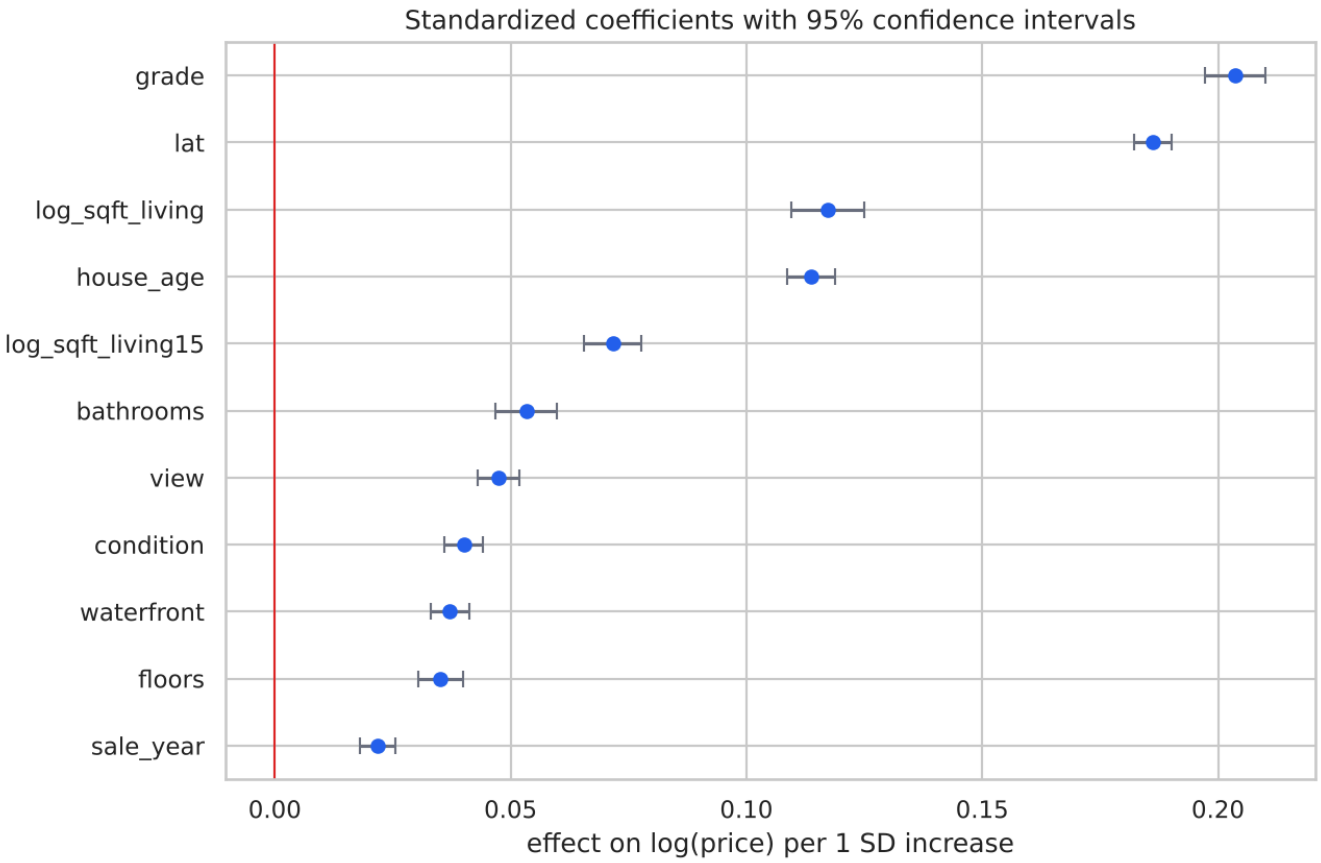
主模型預測公式

```
log(price) = -150.600
             + 0.17426 × grade
             + 1.34572 × lat
             + 0.27657 × log(sqft_living)
             + 0.00387 × house_age
             + 0.06173 × view
             + 0.21884 × log(sqft_living15)
             + 0.06947 × bathrooms
             + 0.42466 × waterfront
             + 0.06153 × condition
             + 0.06519 × floors
             + 0.046633 × sale_year

預測房價（中位數） = exp( log(price) )
預測房價（平均值） = exp( log(price) ) × 1.0327        ← Duan smearing 修正
95% 預測區間 ≈ exp( log(price) ± 1.96 × 0.2519 ) ≈ 預測價 × 0.61 ～ × 1.64
```

其中 house_age = 成交年 − yr_built；殘差標準差 $\hat{\sigma} = 0.2519$。區間的精確值另加上 $x_0^T(X^TX)^{-1}x_0$ 項，程式的 predict_price() 已內建。sale_year 約為 2015，係數的小數位會被放大，故多列一位。以第 6 節的範例房屋代入此公式得約 $503,900，與程式以完整精度算出的

$503,786 一致。



標準化後影響最大的是 grade 與 lat，其次是居住面積與屋齡：房價的關鍵是「品質」與「地段」。waterfront 的原始係數最大，但臨水房只佔 0.75%，標準化後影響較小。

5. Evaluation

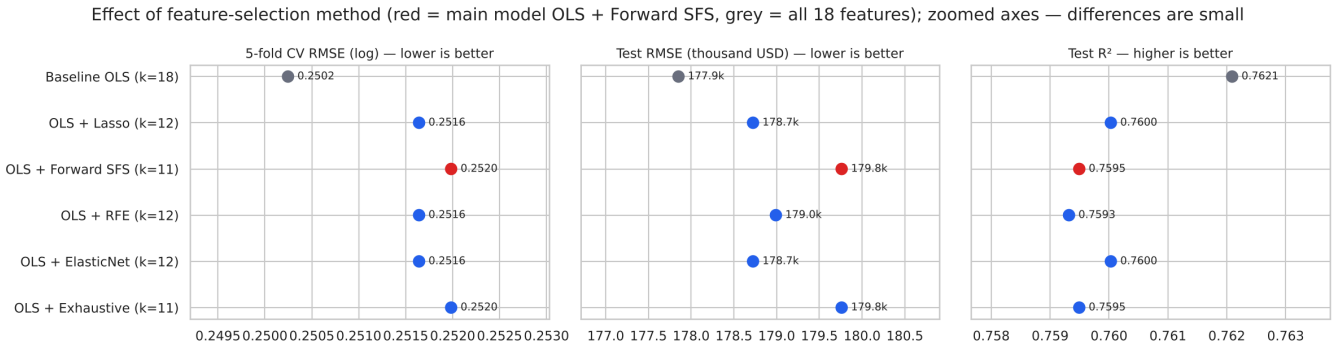
主模型（OLS + Forward SFS，11 個特徵）在測試集達到 $R^2 = 0.760$、RMSE = $179,761。五種特徵選擇方法的 RMSE 差距只有 $1,037（0.6%），與全部 18 個特徵相比也只多 1.1%。

5.1 各特徵選擇方法的測試集評估（測試集 4,320 筆）

模型	k	Test R^2	Test Adj R^2	RMSE（美元）	MAE（美元）	MAPE	95% PI 涵蓋率
Simple LR（只用居住面積）	1	0.4511	0.4510	267,444	167,798	35.7%	95.6%
Baseline OLS	18	0.7621	0.7611	177,852	109,297	20.9%	94.0%
OLS + Lasso	12	0.7600	0.7594	178,724	110,446	21.1%	94.3%
OLS + Forward SFS（主模型）	**11**	**0.7595**	**0.7589**	**179,761**	**110,626**	**21.2%**	**94.4%**
OLS + RFE	12	0.7593	0.7586	178,991	109,769	21.0%	94.1%
OLS + ElasticNet	12	0.7600	0.7594	178,724	110,446	21.1%	94.3%

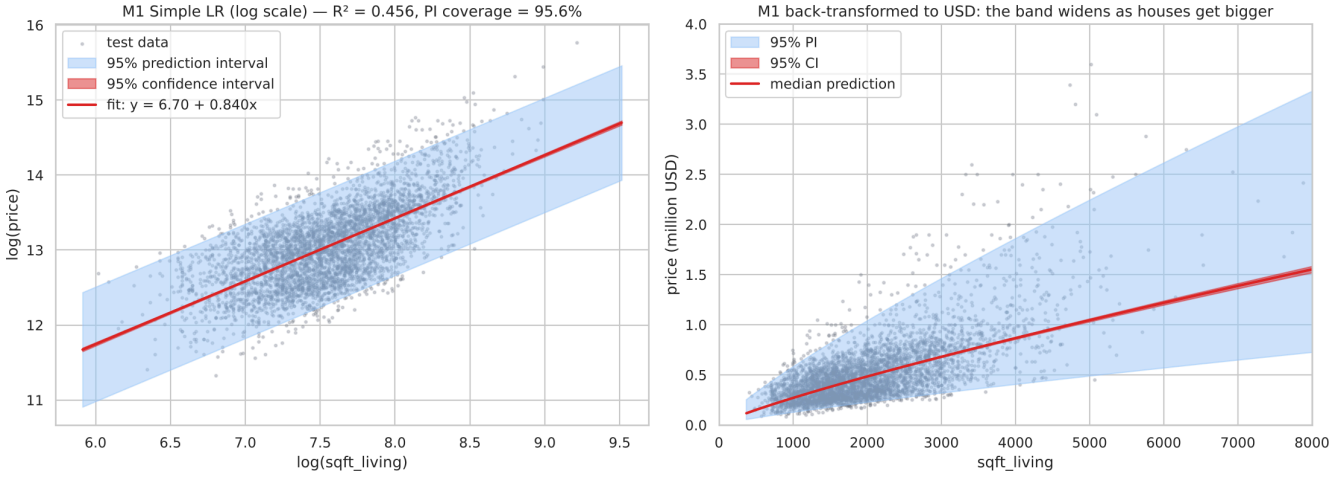
模型	k	Test R^2	Test Adj R^2	RMSE（美元）	MAE（美元）	MAPE	95% PI 涵蓋率
OLS + Exhaustive	11	0.7595	0.7589	179,761	110,626	21.2%	94.4%

R^2 以 log(price) 計算；RMSE、MAE、MAPE 以還原後的美元計算（套用 Duan smearing [8] 修正）。

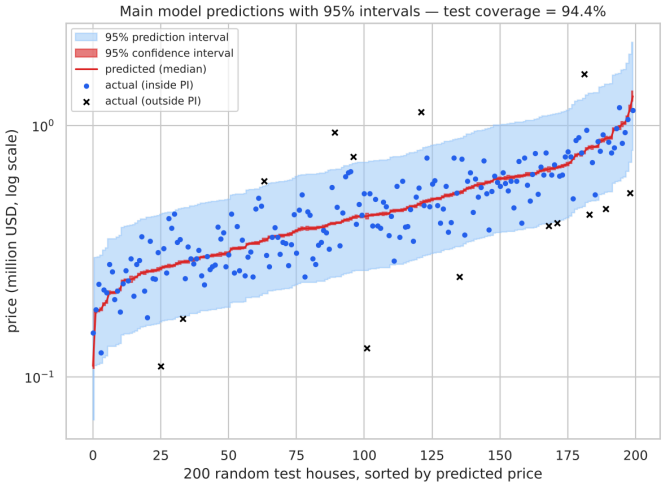


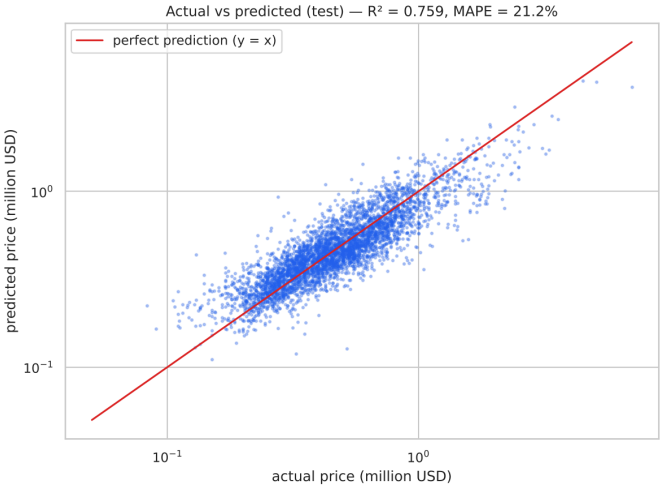
- **特徵選擇方法影響很小**：五種方法 Test RMSE 落在 $178,724～$179,761，Test R^2 差距只有 0.0007；上圖座標軸已放大，實際差異很小。
- **特徵選擇有效**：主模型少用 7 個特徵，RMSE 只多 1.1%；F 統計量從 3,311 升到 5,317，VIF 最大值從 6.88 降到 4.14。
- **沒有過擬合**：主模型 Train R^2 0.772、Test R^2 0.760，兩者接近。
- **多元 vs 單純回歸**：加入其他 10 個特徵，MAPE 從 35.7% 降到 21.2%。
- **預測區間可靠**：所有多元模型的 95% 預測區間涵蓋率都在 94.0–94.4%，接近名目的 95%。

5.2 預測圖（含 95% 信賴區間與預測區間）



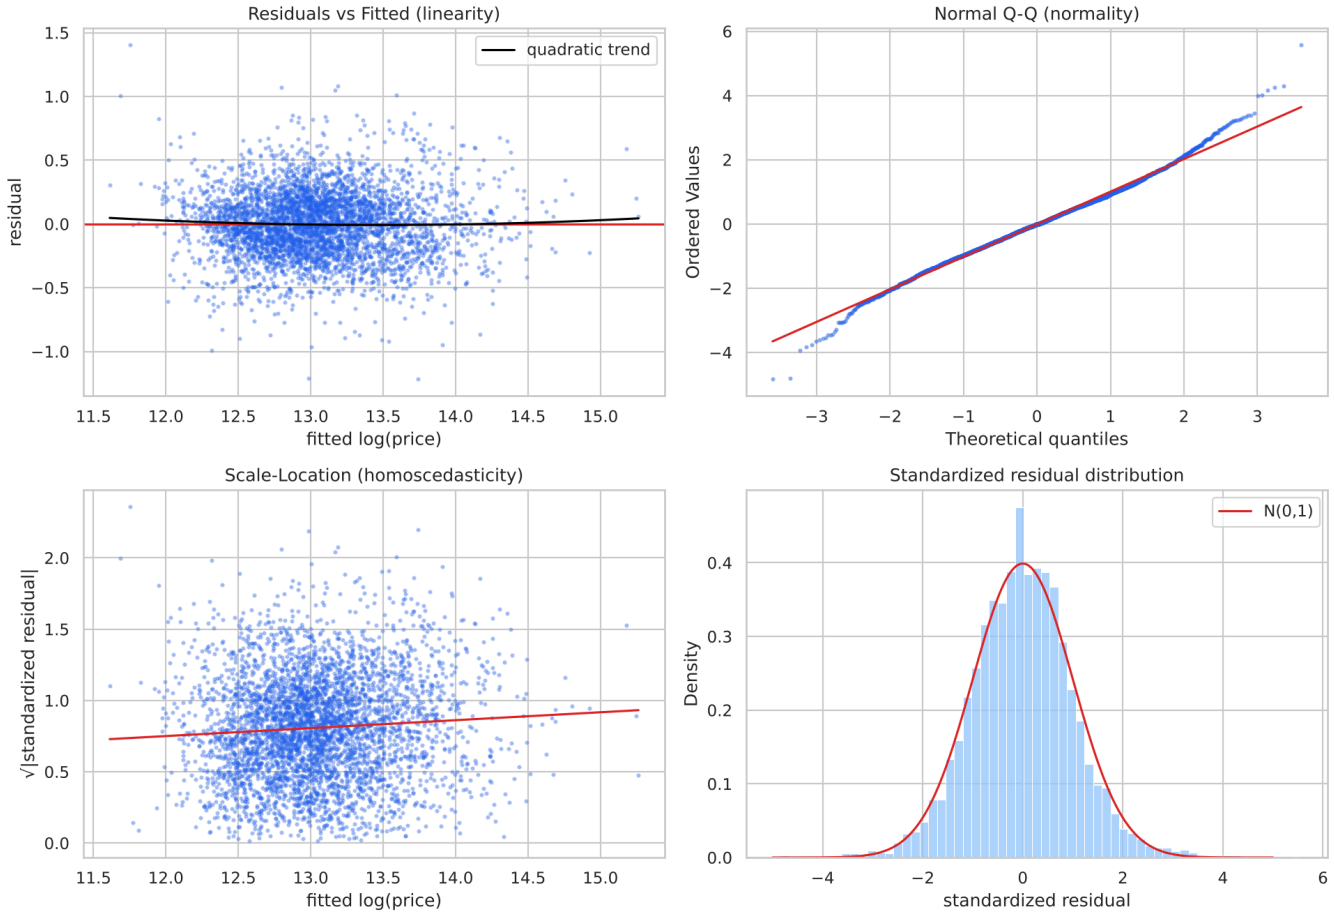
M1 的迴歸式為 log(price) = 6.70 + 0.840 × log(sqft_living)：面積增加 1%，房價約增加 0.84%。紅色 CI 很窄（平均線估得很準），藍色 PI 很寬（單一房屋變異大），測試集 PI 涵蓋率 95.6%。還原為美元後，房子越大區間越寬。





主模型的 95% 預測區間在測試集實際涵蓋 94.4% 的房屋，接近名目的 95%。平均區間約為預測價 ×0.61 至 ×1.64，也就是預測 50 萬美元的房子，實際價大多落在 31 萬到 82 萬之間。

5.3 殘差診斷（Residual Diagnostics）

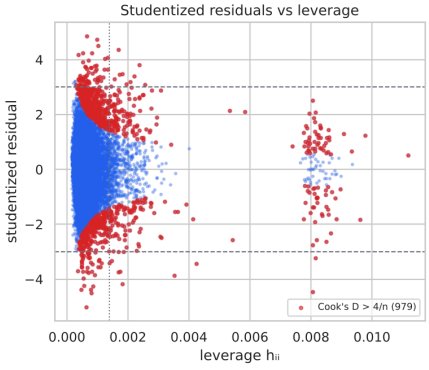


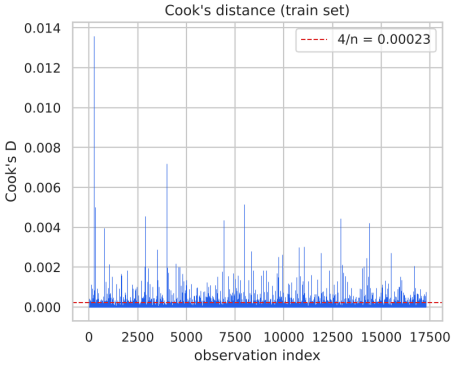
假設	檢查結果	判定
線性	Residuals vs Fitted 大致水平，兩端輕微上彎	大致成立
誤差獨立	Durbin-Watson [9] = 2.02	成立

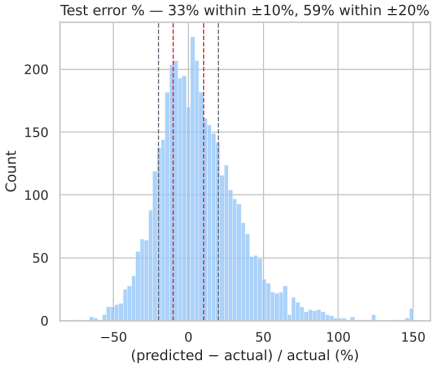
假設	檢查結果	判定
變異數同質	Scale-Location 線略微上升	大致成立
誤差常態	偏態 0.11、峰度 0.84；Jarque-Bera [10] p < 0.001，Q-Q 兩尾偏離	近似常態，尾部較厚
無嚴重共線性	所選 11 個特徵 VIF 最高 4.14	成立

Jarque-Bera 在 1.7 萬筆樣本下對微小偏離也會顯著；從直方圖看殘差仍接近常態。

5.4 離群值與影響點診斷（Outlier & Influence Diagnostics）







診斷	門檻	結果
高槓桿點	$h_{ii} > 2p/n = 0.0014$	884 筆（5.1%）
離群值	｜學生化殘差｜ > 3	132 筆（0.76%）
高影響點	Cook's D > 4/n = 0.00023 [11]	979 筆（5.7%）；最大值 0.014，遠小於 1
敏感度	移除 979 筆後重配	Test R^2 0.7595 → 0.7597；係數最大變動 2.5 個標準誤（floors）
誤差百分比	｜預測 − 實際｜／實際	中位數 16.1%；±10% 內 32.6%，±20% 內 59.0%

- 左圖右側槓桿值約 0.008 的一群點是臨水房（只佔 0.75%，特徵組合特殊）。Cook's D 前 5 名全是臨水、景觀 4 級的房屋，模型都高估了，例如實際 $380,000、預測 $1,164,860。
- 沒有任何單一房屋主導模型：移除所有高影響點後測試表現幾乎不變，故保留全部資料。
- 誤差百分比右側較長：低價房容易被高估，是線性模型未納入地段細節的結果（第 8 節以 zipcode 改善）。

6. Deployment

模型存成 `results/house_price_model.joblib`（只含係數與 $(X^TX)^{-1}$ 等純數值，任何環境都能載入），並提供 `predict_price()`：輸入一間房子的原始欄位，回傳預估價與 95% 預測區間。

範例：3 房 2.25 衛、居住面積 2,000 sqft、地坪 6,000 sqft、2 層、grade 8、condition 3、1995 年建、位於 lat 47.60 / long -122.20（Bellevue 一帶）、2015 年 6 月成交。

- 預估價格（中位數）：**$503,786**
- 95% 預測區間：**$307,482 ~ $825,415**

上線方式與注意事項

- 模型檔可由 Flask、FastAPI 或 Streamlit 載入，做成線上估價頁面。
- 同時顯示「點估計」與「95% 預測區間」，讓使用者知道估價的不確定性。
- 資料為 2014–2015 年成交，實際使用需以新成交資料定期重新訓練，並監控誤差是否漂移。
- 模型只適用於 King County 範圍內、條件落在訓練資料範圍內的一般住宅。

7. NotebookLM 研究摘要

【NotebookLM 摘要】

針對 King County 房屋交易資料集（King County House Sales Dataset）的多元線性回歸與房價預測研究，網路上的高分方案與學術論文普遍採用系統化的資料預處理與特徵工程流程，主要集中於以下四大關鍵維度：

1. **目標變數與偏態特徵之對數轉換（Log Transformation）**：由於房價（price）及居住面積（sqft_living）呈現顯著的右偏分佈，主流解法皆對目標變數進行對數轉換（取 log(price)）。此舉能有效減輕極端值影響，使殘差更符合常態分佈與同變異性（Homoscedasticity）假設，顯著提升線性模型的擬合效果。
2. **時間與屋齡衍生特徵工程（Feature Engineering）**：研究方案多將交易日期 date 拆解出銷售年份與月份，用以捕捉房市季節性趨勢；同時結合建築年份 yr_built 與翻修年份 yr_renovated 衍生出「實際屋齡（house_age）」與「翻修時間間隔（years_since_reno）」，顯著增強了對房屋價值的解釋能力。
3. **地理位置編碼（Location Signaling）**：King County 的地段對房價影響極大。優秀解法通常利用 zipcode 或經緯度進行 Target Encoding 或區域 Dummy 變數轉換，亦有研究結合 K-Means 聚類演算法對地理區位進行分群，以精準捕捉微觀地段溢價。
4. **共線性診斷與模型比較（Diagnostic & Model Comparison）**：在建模階段，常見作法是以多元共線性檢測（VIF）剔除高度相關變數（如 sqft_living 與 sqft_above），並搭配 Ridge/Lasso 正規化進行變數篩選。多元線性回歸作為基準模型通常可達到 $R^2 \approx 0.70 \sim 0.78$ 的解釋力；若進一步融合梯度提升樹（如 CatBoost、LightGBM）等非線性模型，整體預測精度可進一步提升至 $R^2 \geqslant 0.85$。

與本報告結果對照：本報告已採用上述第 1、2、4 項做法（log 轉換、house_age 與 sale_year/sale_month、VIF 與 Lasso/ElasticNet）。主模型測試集 $R^2 = 0.760$，落在文獻所述的 0.70～0.78 區間；第 8 節加入第 3 項的 zipcode Dummy 變數後達 0.871，Gradient Boosting 達 0.901，與文獻「$R^2 \geq 0.85$」的結論一致。

研究來源（加入 NotebookLM 的資料）

- [12] Predicting Housing Prices Using Multiple Linear Regression（RPubs）：使用多元線性回歸模型對 King County 資料集進行預測與殘差分析。
- [13] Winning Kaggle Solution: Predicting property sales prices（RPubs）：Kaggle 競賽房價預測範例，包含對數轉換與變數選擇策略。
- [14] Real-estate price prediction for King County region（Stanford CS229，2019）：King County 地區房價預測之機器學習與線性回歸研究報告。

8. 網路主流與更優解法比較

加入 zipcode one-hot 後，線性回歸的測試集 R^2 從 0.760 升到 0.871，代價是特徵數從 11 個增為 80 個。樹模型（Gradient Boosting）達 0.901，但失去係數的可解釋性。三個模型使用同一組訓練／測試切分。

模型	特徵數	Test R^2	5-fold CV R^2	RMSE（美元）	MAPE	95% PI 涵蓋率	可解釋性
主模型（OLS + Forward SFS）	11	0.760	0.772	179,761	21.2%	94.4%	高：每個係數都有意義
M6 MLR + zipcode one-hot	80	0.871	0.878	128,884	14.3%	93.9%	中：多了 69 個地段虛擬變數
M7 HistGradientBoosting（參考）	18	0.901	0.901	121,144	12.2%	—	低：黑箱，無公式式區間

說明

- **地段是最大的改善來源**。lat/long 只能表示「往北越貴」這種線性趨勢，無法表示 Bellevue、Medina 這類個別高價區。zipcode one-hot 讓每個區有自己的溢價，M6 的預測區間平均寬度也從 0.988 縮到 0.721（log 尺度）。
- **Kaggle 常見做法**：一是價格與面積取 log（本報告已採用）；二是地段特徵工程（zipcode 編碼、距離市中心距離）；三是改用 Random Forest、XGBoost、LightGBM 等樹模型 [12][13][14]。
- **為何仍以 11 特徵 OLS 為主模型**：作業要求線性回歸與 10–20 個特徵；主模型的每個係數都能解讀成「條件提升一單位，房價變化幾 %」，預測區間也有完整的統計公式。若以準確度為優先，M6 是線性模型中最佳的選擇。

9. GPT 輔助內容（與 Claude 的對話過程）

以下為本作業使用 AI 的對話紀錄。「學生」為本人輸入的原文；「Claude」為 AI 回覆原文（第 12–16 輪為節錄）。Claude 在背景執行程式、讀寫檔案的工具操作過程不列入；學生訊息中附的圖片與檔案以（…）註明。

9.1 與 Claude 的對話（資料集選擇、分析與報告）

第 1 輪 — 學生

（附上作業說明檔）請幫我依據這份說明 幫我完成作業 一步步來 首先是找尋能用的資料集

第 1 輪 — Claude

第一步：選定資料集

先提醒一個條件衝突：作業說明要求 **10–20 個特徵**，但你之前問 GPT 時設定的是 14–39 個。以作業說明為準，所以**剛好 20 個特徵的資料集**最安全，兩個條件都符合。依這個標準：

- **Concrete Strength**（8 個特徵）太少，不符合。
- **House Prices**（79 個特徵）太多，不符合。

推薦：Kaggle Playground Series S4E5 — Regression with a Flood Prediction Dataset（https://www.kaggle.com/competitions/playground-series-s4e5）

為什麼選它：

1. **特徵數剛好 20 個，全是數值型。** 包括 MonsoonIntensity、TopographyDrainage、RiverManagement、Deforestation、Urbanization、ClimateChange 等，目標變數是 FloodProbability（連續值）。資料包含人口、土地、氣候與政治因素共 20 個自變數，依變數為 FloodProbability，測試集有 745,305 筆。不需要處理類別編碼，可以專心做特徵選擇和評估。
2. **它是競賽，可以拿到 Kaggle 名次。** 評分標準有 10% 是「呈現 Kaggle 名次（若有）」，選競賽型資料集可以直接拿到這部分分數。評估指標是 R^2，和線性回歸的報告方式一致。
3. **網路上解法很多。** 競賽資料有約 112 萬筆訓練樣本與 74.5 萬筆測試樣本，特徵源自 Flood Prediction Factors 資料集。之後用 NotebookLM 研究、做「主流解法比較」時，素材很充足。
4. **適合線性回歸。** 這份資料的目標和特徵之間接近線性關係，所以線性回歸的 R^2 表現不錯，畫預測區間圖也很好看。社群常見的作法是把 20 個特徵加總成新特徵，這個發現可以寫進「更優解法比較」。

備案： 原始版本的 Flood Prediction Dataset（約 5 萬筆，同樣是 20 個特徵）：https://www.kaggle.com/datasets/naiyakhalid/flood-prediction-dataset 。資料量小，跑起來比較快，但沒有排行榜。我建議主程式用競賽版，原始版可以拿來當補充驗證。

接下來請你做的事：我這邊的環境無法直接連到 Kaggle 下載，所以需要你：

1. 登入 Kaggle，進入上面的競賽頁面，按 **Join Competition / Late Submission**。

2. 到 **Data** 分頁下載 train.csv、test.csv、sample_submission.csv。
3. 把檔案上傳到這個對話。檔案太大的話，至少先上傳 train.csv，或者先上傳原始版的 5 萬筆資料集。

收到檔案後，下一步我會做 **Business Understanding + Data Understanding**，包括資料概況、缺值檢查、分布圖和相關係數熱圖，並開始寫 7114056XXX_hw2.ipynb 主程式。另外，你的學號後三碼是多少？我會直接寫進檔名。

第 2 輪 — 學生

我想用這個資料集 https://www.kaggle.com/datasets/harlfoxem/housesalesprediction 接下來請幫我依據他的要求分析 2. 分析任務：使用線性回歸 (Linear Regression) 模型進行預測。可嘗試單純線性回歸、多元線性回歸或 Auto Regression。必須執行 特徵選擇 (Feature Selection) 與 模型評估 (Model Evaluation)。結果部分需包含請提供預測圖(加上信賴區間或預測區間)

第 2 輪 — Claude

分析任務的完整程式已經寫好了（7114056XXX_hw2.ipynb）。不過要先說明：**我這邊連不到 Kaggle，所以還沒用真實資料跑過。** 我是用一份欄位格式完全相同的模擬資料，確認程式從頭到尾都能執行、10 張圖都正常產生。測試時看到的數字（R^2 約 0.78 等）都是假資料的結果，**不能寫進報告**。

程式涵蓋的分析任務：

作業要求	程式中的做法
資料集特徵數	21 欄，扣掉 id、date、price 剩 18 個特徵，符合 10–20 個的要求
線性回歸模型	共 5 個模型互相比較：M1 單純線性回歸（只用居住面積）、M2 全特徵多元線性回歸、M3 特徵選擇後的多元線性回歸（主模型）、M4 Ridge、M5 Lasso
特徵選擇	4 種方法：F 檢定（Filter）、Forward Selection + 5-fold CV、RFE、LassoCV，最後整理成一張比較表；另外用 VIF 檢查共線性。特徵選擇只在訓練集上做，避免資料洩漏
模型評估	R^2、Adjusted R^2、5-fold CV R^2、RMSE、MAE、MAPE（換回美元計算），加上殘差四圖診斷、Durbin-Watson、Jarque-Bera
預測圖＋區間	① 單純線性回歸的 95% 信賴區間與 95% 預測區間帶狀圖；② 主模型對測試集 200 間房子的預測圖，同時畫出 CI 和 PI，並標出落在區間外的點，計算實際涵蓋率

作業要求	程式中的做法
Deployment	存成模型檔，提供 predict_price()：輸入一間房子的條件，回傳預估價格和 95% 預測區間

預處理的重點：價格和面積都取 log（房價右偏），刪掉 33 房的錯誤資料，sqft_above 因為與其他面積欄位完全共線而刪除。

下一步，兩種做法擇一：

1. **把 kc_house_data.csv 上傳到這個對話**（約 2.4 MB）。我會用真實資料跑完，檢查結果是否合理，再把真實的圖表和數字交給你，接著幫你寫報告的 CRISP-DM 各章節。
2. **自己用 Colab 跑**：打開 notebook 後選「全部執行」。程式偵測不到 CSV 時，會自動透過 kagglehub 從 Kaggle 下載。

另外提醒：這份是 Kaggle 一般資料集，不是競賽，所以**沒有 Kaggle 名次**。評分項目中的這部分（10%），會改以預測圖和評估指標來呈現，報告裡要寫清楚這一點。

第 3 輪 — 學生

（上傳 kc_house_data.csv）這是我的資料集 然後你幫我依據 crisp-dm 的方法作 以集作業要求的方式分析並完成 2. 分析任務 並將它打成文件檔 和生成程式碼 我的學號是7115056079

第 3 輪 — Claude

我用你上傳的真實資料跑完了分析，報告和程式都做好了。主模型在測試集的 R^2 是 0.762，達到原本設定的 0.75 目標，作業的「分析任務」要求全部都有涵蓋。

主要結果：

- **特徵選擇：** 18 個候選特徵保留 15 個，排除 has_basement、long、sale_month。Forward Selection 和 RFE 選出的結果完全一樣。
- **評估指標：** 交叉驗證 R^2 為 0.775，MAPE 為 21.0%。訓練集、測試集和交叉驗證的分數很接近，沒有過擬合。
- **預測圖：** 主模型的 95% 預測區間在測試集實際涵蓋了 94.1% 的房屋，接近 95%。另外有一張單純線性回歸的圖，同時畫出信賴區間和預測區間。
- **更優解法比較：** 加入 zipcode 後 R^2 升到 0.878；樹模型可到 0.901，但沒辦法解讀係數。

交付的檔案：

- **報告：** 已經依 CRISP-DM 的六個階段寫好，10 張圖都放進去了，可以直接匯出成 PDF 或 Word 繳交。
- **程式：** 7115056079_hw2.ipynb 打開就能看到每段的執行結果和圖表，.py 是同樣的內容。
- **壓縮檔：** 7115056079_hw2.zip 裡面有程式、資料、圖表和模型檔。

還需要你自己完成的部分（報告第 8 節已經留好位置和勾選清單）：

1. **NotebookLM 摘要（100 字以上）：** 這部分需要你用自己的帳號實際操作，我無法代做。

2. **對話紀錄：** 把和 ChatGPT 的對話用 pdfCrowd 匯出。作業內容主要是和我（Claude）一起完成的，所以報告裡我把這部分標成「AI（Claude）輔助內容」，建議這份對話也一起匯出附上。
3. **最終打包：** 報告 PDF 匯出後放進 zip，再上傳。

第 4 輪 — 學生

幫我寫出作業需要的報告 然後空出需要用NotebookLM研究摘要 （100 字以上）的地方 和你的對話 一併幫我寫入檔案內

第 4 輪 — Claude

報告寫好了，共 14 頁，NotebookLM 摘要的位置已經空出來，我們的對話紀錄也寫進去了。

報告裡新增的兩個部分（都在第 8 節）：

- **8.1 NotebookLM 研究摘要：** 有一個標著【NotebookLM 摘要】的填寫區，留了空白線，下面有 3 格填研究來源網址。旁邊附了操作建議，告訴你要把哪些網頁加入 NotebookLM、要問什麼問題。
- **8.2 GPT 輔助內容：** 包括你之前和 ChatGPT 的資料集篩選對話，以及我們這 4 輪的對話。你的提問照原文寫入；我的回覆含有大量程式碼，所以只整理重點。最後有一張表，分清楚哪些是 AI 協助的、哪些是你自己做的。

另外修正了一個問題：信賴區間和預測區間的公式在 PDF 裡原本會顯示成 LaTeX 原始碼，已經改成一般文字。

繳交前要做的事：

1. 用 NotebookLM 寫好摘要（100 字以上），貼進 7115056079_hw2_report.docx 的 8.1，填好來源網址，刪掉操作建議那一段，再另存成 PDF。
2. 用新的 PDF 替換掉 7115056079_hw2.zip 裡的舊版。
3. 8.2 寫的是「完整對話另以 PDF 匯出附於壓縮檔」。作業要求附 pdfCrowd 匯出的對話，所以請把 ChatGPT 和這次對話各匯出一份 PDF，放進 zip。

線上版報告也已經同步更新，要在那邊修改也可以，改完能直接匯出 PDF 或 Word。

第 5 輪 — 學生

這是NotebookLM 寫得摘要 關於 King County 房價預測與多元線性回歸分析 的網路解法，我們進行了深入的文獻與技術報告檢索。針對此一經典資料集，網路上主流的解法與優化策略主要集中於以下四大關鍵維度：網路上同主題解法摘要（可直接納入報告中）在針對 King County 房屋交易資料集（King County House Sales Dataset）進行多元線性回歸與房價預測的研究中，網路上的高分方案與學術論文普遍採用了系統化的資料預處理與特徵工程流程：目標變數與偏態特徵之對數轉換（Log Transformation）：由於房價（price）及居住面積（sqft_living）呈現顯著的右偏分佈，主流解法皆對目標變數進行對數轉換（取 log(price)）。此舉能有效減輕極端值影響，使殘差更符合常態分佈與同變異性（Homoscedasticity）假設，顯著提升線性模型的擬合效果。時間與屋齡衍生特徵工程（Feature Engineering）：研究方案多將交易日期 date

拆解出銷售年份與月份，用以捕捉房市季節性趨勢；同時結合建築年份 yr_built 與翻修年份 yr_renovated 衍生出「實際屋齡（house_age）」與「翻修時間間隔（years_since_reno）」，顯著增強了對房屋價值的解釋能力。地理位置編碼（Location Signaling）：King County 的地段對房價影響極大。優秀解法通常利用 zipcode 或經緯度進行 Target Encoding 或區域 Dummy 變數轉換，亦有研究結合 K-Means 聚類演算法對地理區位進行分群，以精準捕捉微觀地段溢價。共線性診斷與模型比較（Diagnostic & Model Comparison）：在建模階段，常見作法是以多元共線性檢測（VIF）剔除高度相關變數（如 sqft_living 與 sqft_above），並搭配 Ridge/Lasso 正規化進行變數篩選。多元線性回歸作為基準模型通常可達到 $R^2 \approx 0.70 \sim 0.78$ 的解釋力；若進一步融合梯度提升樹（如 CatBoost、LightGBM）等非線性模型，整體預測精度可進一步提升至 $R^2 \geqslant 0.85$。

第 5 輪 — Claude

NotebookLM 摘要已經放進報告 8.1，PDF、Word 和 zip 都重新產生了，報告現在共 15 頁。

摘要內容我保留原文，只動了三處：

- 刪掉 NotebookLM 自己的開場白和「(可直接納入報告中)」這類提示語。
- 四大重點改成編號 1–4 的清單，比較好讀。
- R^2 的 LaTeX 寫法在 PDF 裡會顯示成原始碼，所以改成「$R^2 \approx 0.70$〜0.78」。

摘要後面我加了一段「與本報告結果對照」：主模型 $R^2 = 0.762$，落在文獻說的 0.70〜0.78 之間；加入 zipcode 之後是 0.878，樹模型是 0.901，和文獻「$R^2 \geqslant 0.85$」的說法一致。這段是我寫的，不是 NotebookLM 產生的，標題用粗體分開。如果不想放，刪掉這一段就好。

還沒完成的部分：

- **研究來源網址：** 8.1 底下的 3 格還是空的，請填入你加進 NotebookLM 的網址。在 Word 檔填完後另存成 PDF，替換掉 zip 裡的報告就好。
- **對話 PDF：** 和 ChatGPT 以及這次的對話，請各匯出一份 PDF 放進 zip。

第 6 輪 — 學生

（附上一張「特徵 vs log(price)」對比圖的截圖）我想請你幫我改幾個地方　然後先給我看看文件檔改得如何了　最後我再請你幫我把所有打包成壓縮檔　收先是第一頁上方的@ｓｕｎｎｙ幫我刪掉　第二頁的數據分析　你可以幫我把所有的數據跟房價的對比圖（我貼給你的）這裡幫我把所有的都貼上來　　你給我看完擬改的這兩三頁後再繼續

第 6 輪 — Claude

兩處都改好了，先請你看改動的這幾頁。

1. **第 1 頁：** 已刪掉「@sunny」，作者那一行現在只剩日期和學號 7115056079。
2. **Data Understanding（第 3–5 頁）：** 原本的 6 張對比圖換成**全部 18 個特徵 vs 房價**。
   - 18 張圖照「和房價的相關程度」由高到低排列，每張標題都標了相關係數 r。
   - 18 張放在同一頁會太小，所以拆成兩張：第 4 頁是第 1–9 名，第 5 頁是第 10–18 名。

- 有 15 種以下取值的特徵（像 grade、view）用箱型圖，其他用散佈圖。
- sqft_lot 和 sqft_lot15 的數值差距太大，x 軸改成對數刻度。
- 圖下方加了 5 點觀察：哪些特徵和房價明顯正相關；lat 和 floors 不是直線關係；地下室面積和翻修年份大多是 0；zipcode 要當成類別處理；屋齡和屋況單看幾乎沒關係，控制其他條件後才變得顯著。

報告因此從 15 頁變成 17 頁。程式也同步改好了，重新執行就會產生這兩張新圖。這幾頁沒問題的話，請告訴我還有哪些要改，全部改完我再打包成壓縮檔。

第 7 輪 — 學生

你儘量幫我不要留空　圖可以往上減少頁面　就盡量幫我往上　接著要改的是建模　你先告訴我你怎麼完成分析任務的　有包含這些嗎

1. 核心回歸模型 (Base Regression Model)：基底模型 (Baseline OLS)：使用普通最小平方面積 (Ordinary Least Squares, OLS) 多元線性回歸模型作為基準，建立起特徵支出與預測 Profit（利潤）之間的線性關係。
2. 特徵選擇演算法 (Feature Selection Algorithms)：為了尋找最佳的特徵組合，該網站評估並比較了以下 5 種特徵選擇與機器學習演算法：Lasso (L1 正則化)：透過 L1 懲罰項將不重要的特徵係數壓縮至 0，自動篩選出關鍵特徵。Forward SFS (前向序列特徵選擇)：從 0 個特徵開始，每次選擇能最大幅提升模型表現的特徵加入，直到達到指定特徵數 k。RFE (遞迴特徵消除)：從包含所有特徵的模型開始，重複訓練並移除最不重要的特徵。ElasticNet (彈性網路正則化)：結合 Lasso (L1) 與 Ridge (L2) 懲罰項，在特徵共線性高時能更加穩定地選擇特徵。Exhaustive Search (窮舉搜尋)：測試所有可能的特徵子集組合，確保找到特定特徵數量下表現最佳的組合。
3. 特徵數量與模型評估機制 (Model Selection & Diagnostics)：在評估不同算法時，網站比較了特徵數量 k = 1 到 5 的表現，並使用以下統計指標：過擬合與簡約性分析 (Parsimony Analysis)：甜點區 (Sweet Spot)：找出當特徵數 k=2（通常為 R&D Spend 與 Marketing Spend）時，能夠達成最小的 Test RMSE（約 $8,198.80）與極高的 R^2（0.9474）。過擬合警告 (Overfitting Cliff)：觀察當特徵數增加至 k=5 時，Test RMSE 上升（$9,137.99），呈現過擬合現象。模型統計檢驗：計算 R^2、Adjusted R^2、MAE、F-Statistic (p-value) 評估模型擬合度。VIF (Variance Inflation Factor)：檢測特徵間的共線性 (Multicollinearity)。殘差與離群值診斷 (Residual Diagnostics)：分析測試集（Test Set）的殘差分佈與誤差百分比。

第 7 輪 — Claude

先說明一件事：你貼的這份清單，來源網站分析的是另一個資料集（50 Startups，用 R&D Spend、Marketing Spend 預測 Profit），不是房價。所以它的數字（k=2 是甜點區、RMSE 約 $8,198、$R^2$ 0.9474、k=5 開始過擬合）都不能直接套用。不過它的**方法架構**可以照做。下面逐項對照我目前做了什麼。

清單項目	目前狀態	我的做法
1. Baseline OLS	✅ 有	M2 用全部 18 個特徵跑 OLS 當基準。係數、標準誤、p-value、CI、PI 都是照公式自己算的。目標變數是 log(price)，不是 Profit
Lasso (L1)	✅ 有	LassoCV 自動選 alpha
Forward SFS	✅ 有	從 0 個特徵開始逐一加入，以 5-fold CV R^2 判斷，跑完 k = 1–18
RFE	✅ 有	標準化後遞迴刪除特徵
ElasticNet	❌ 沒有	我另外做了 F 檢定（Filter）和 Ridge，沒有做 ElasticNet
Exhaustive Search（窮舉）	❌ 沒有	
比較各 k 的表現	⚠️ 部分	只有 Forward 一種方法有 k = 1–18 的 CV R^2 和 BIC 曲線。沒有「每種方法 × 每個 k」的 Test RMSE 比較表
甜點區 / 過擬合分析	⚠️ 部分	我用「CV R^2 和最高值差 < 0.002 時取 BIC 最小」選出 k = 15，但沒有明確寫成甜點區和過擬合的分析
R^2、Adjusted R^2、MAE	✅ 有	另外還有 RMSE、MAPE、CV R^2
F-Statistic（p-value）	❌ 沒有	只做了每個係數的 t 檢定，沒有整體模型的 F 檢定
VIF	✅ 有	全部 < 7
殘差診斷	✅ 有	殘差四圖、Durbin-Watson、Jarque-Bera
誤差百分比	✅ 有	MAPE 21.0%
離群值診斷	❌ 沒有	沒有做 Cook's distance 或高槓桿點分析

建議補上的內容（改程式後重新執行）：

1. **ElasticNet：** 加入成第 5 種特徵選擇方法。
2. **Exhaustive Search：** 18 個特徵共有 26 萬種組合。我用 X'X 矩陣的方式，可以在幾分鐘內全部算完，找出每個 k 下最好的組合。
3. **5 種方法 × k 的比較：** 做一張表加一張折線圖，比較 Lasso、Forward SFS、RFE、ElasticNet、Exhaustive 在每個 k 的 Test RMSE 和 R^2。清單只比 k = 1–5，我建議比到 1–18，因為房價資料要 10 個以上特徵才會趨於穩定。
4. **甜點區與過擬合分析：** 找出 Test RMSE 最低的 k，以及之後是否開始上升。預先說明：這份資料有 1.7 萬筆、特徵只有 18 個，很可能**不會**出現明顯的過擬合，曲線會走平而不是變差。我會照實際結果寫，不會套用那個網站的結論。

5. **整體 F 檢定：** 在 OLS 摘要加上 F 統計量和 p-value。
6. **離群值診斷：** 加上 Cook's distance 和槓桿值圖，列出影響最大的幾筆房屋。

版面留白： 留白是因為圖太高、塞不進當頁剩下的空間，只好換到下一頁。建模這節改完後，我會一起調整：把圖改矮一點、讓說明文字排在圖前面，盡量把圖往上補滿空白，減少頁數。

這 6 項你都要加嗎？確認後我就開始改，改完先給你看 Modeling 那幾頁。

第 8 輪 — 學生

你不需要一次把九張擺在一起　以三個為一組安排就好　比較彈性　也不用刻意縮小圖　我希望如你所說　以這份網站的這份框架補上剛剛你說的可以補上的內容

第 8 輪 — Claude

Modeling 已經照那個網站的架構改好了，特徵對比圖也改成每 3 個一組。

有一個結果變了，請你確認：主模型從 15 個特徵改成 11 個。 這是照網站的「簡約性分析」選出來的：在交叉驗證誤差和最佳值差不到 0.002 的前提下，選特徵數最少的 k，結果是 k = 11。代價很小：測試集 R^2 從 0.762 降到 0.760，誤差多約 1%，但少用 7 個特徵。報告裡所有相關數字都已經同步更新。如果你想維持 15 個特徵，跟我說一聲就可以改回來。

Modeling 現在的架構（第 6–10 頁）：

- **4.1 Baseline OLS：** 用全部 18 個特徵建立基準模型，加上整體 F 檢定（F = 3,310.8，p < 0.001）。
- **4.2 五種特徵選擇方法：** Lasso、Forward SFS、RFE、ElasticNet、窮舉搜尋（26 萬種組合全部算過）。有一張表列出 18 個特徵在每種方法裡的排名。
- **4.3 比較不同特徵數 k：** 一張折線圖比較 5 種方法在 k = 1–18 的測試誤差；甜點區：測試誤差最低落在 k = 14–15；過擬合：**這份資料沒有出現網站說的過擬合懸崖**，曲線從 k ≈ 9 之後就變平，沒有回升，原因是那個網站只有 50 筆資料，這裡有 1.7 萬筆；共線性：選出的 11 個特徵 VIF 都低於 5。
- **4.5 主模型係數表：** 換成 11 個特徵，並加上整體 F 檢定（F = 5,317.3）。

Evaluation 新增 5.4 離群值診斷（第 13 頁）：用槓桿值、學生化殘差、Cook's distance 檢查離群值和高影響點；影響最大的 5 間房子全部是臨水房，模型都高估了它們的價格；移除所有高影響點後重跑，測試結果幾乎沒變，所以保留全部資料；測試集誤差百分比的中位數是 16.1%，59% 的房子誤差在 ±20% 以內。

版面：小圖改成一排 3 張之後，大部分空白都補起來了，報告現在是 18 頁。程式也同步更新了，notebook 已重新執行並存好結果。接下來有兩件事要你決定：主模型要用 11 個還是 15 個特徵？還有哪些地方要改？

第 9 輪 — 學生

我改了一些　這是在數據分析那裏　ｃｏｎｖｒａｎｃｅ矩陣底下的　　下列 18 張圖（每列 3 張）為全部 18 個特徵與 log(price) 的對比，依與房價的相關係數 |r| 由高到低排列。類別型特徵（≤ 15 種取值）以箱型圖呈現，連續型以散佈圖呈現；sqft_lot 與 sqft_lot15 極度右偏，x 軸改

用 log 尺度。　還有你比較的五個模型　是有改了嗎還是沒改　我主要想請你比較不同特徵選法的影響　然後在往下繼續模型評估

第 9 輪 — Claude

你在 Data Understanding 改的那段說明（「下列 18 張圖（每列 3 張）…」）我保留原樣，沒有動。

你問「五個比較模型」有沒有改： 上一版只改了一半。主模型換成 11 個特徵，但 Ridge 和 Lasso 兩個模型還是用全部 18 個特徵，跟特徵選擇方法沒有關係。這次已經整節換掉，改成比較「各特徵選擇方法建出的模型」，然後接到模型評估。

4.4 不同特徵選擇方法的影響：五種方法都用同一個簡約規則選特徵數。

方法	選出幾個	和主模型的差別
Forward SFS、窮舉搜尋	11	兩者選出的完全相同，就是主模型
Lasso、ElasticNet	12	兩者相同，多選了 is_renovated
RFE	12	多了 bedrooms 和 log_sqft_lot15，少了 sale_year

新增一張熱圖，標出每種方法各選了哪些特徵。結論：有 10 個核心特徵五種方法全部都選了，所以結論不太受選擇方法影響，差別只在第 11–12 個特徵。

5.1 各方法的測試集評估：一張表列出 7 個模型的測試集表現；五種方法的 RMSE 只差 $1,037（0.6%），$R^2$ 差 0.0007；主模型比 18 個特徵少用 7 個，誤差只多 1.1%，VIF 最高從 6.88 降到 4.14；比較圖改成點狀圖。

5.2 之後的預測圖、殘差診斷和離群值診斷，用的都是同一個主模型，內容不受影響。程式已經同步更新，notebook 重新執行過了。還有哪裡要改嗎？

第 10 輪 — 學生

我想問　就是這份作業只分析一個就好了嗎　然後還有一些要改　第 8 大點最後的研究來源　是這三個　https://rpubs.com/staneaurelius/house_price_prediction（RPubs：使用多元線性回歸模型對 King County 資料集進行預測與殘差分析）、https://rpubs.com/nweissm/670674（RPubs：Kaggle 競賽房價預測範例，包含對數轉換與變數選擇策略）、https://cs229.stanford.edu/proj2019aut/data/assignment_308832_raw/26646708.pdf（史丹佛大學 CS229：King County 地區房價預測之機器學習與線性回歸研究報告）　還有與ｃｈａｔｇｐｔ的對話改為與ｃｌａｕｄ的對話　並將新對話也貼上去　最後的ＡＩ輔助內容　ｎｏｔｅｂｏｏｋＬＭ摘要　幫我改就是ｎｏｔｅｂｏｏｋＬＭ寫的就行　然後再給我看看　最後的參考資料你可以把你的參考資料也列上去並以［１］、［２］標住在上方的報告內容　並以列點的形式放在參考資料裡　做完給我看最終搞

第 10 輪 — Claude

最終稿好了：PDF 和 Word 各一份，共 20 頁，16 張圖都有正確顯示。

你問「只分析一個就好嗎」： 對，一個資料集就夠了。作業要求是「至 Kaggle 選擇**一個**具有 10 至 20 個特徵的公開資料集」。分析任務要求的特徵選擇和模型評估，報告裡已經在這個資料集上比較了 5 種特徵選擇方法和 7 個模型，不需要再找第二個資料集。

你列的修改，文件裡都已經完成：研究來源（8.1）填入你給的三個網址，標成 [12]–[14]，三個網址我都打開確認過；對話紀錄（8.2）ChatGPT 那段已經拿掉，改成「與 Claude 的對話」；AI 輔助範圍表的 NotebookLM 那一列改成「由 NotebookLM 根據 3 篇研究來源產生摘要」；參考資料共 14 筆，用列點排列，正文裡相關的地方都標了 [1]–[14]。

我另外修了一個問題： 匯出工具最多只能放 16 張圖，報告原本有 17 張，第 14 頁的離群值診斷圖因此變成空白框。我把 4.3 的兩張特徵數比較圖合併成一張，分成 (a)(b)(c) 三格，現在 16 張圖全部都在。確認沒問題的話跟我說，我就把報告、程式、notebook、資料和圖表打包成 7115056079_hw2.zip。

第 11 輪 — 學生

（附上 4.3 的 k 對照表截圖）這張圖 如果報告中沒有明確說要 善調也不影響的話 請幫我刪掉 若有影響 請幫我列出1-18然後重要的轉折幫我標粗體 1-5不一定要標 如果不怎麼重要的話 然後4.5主模型那邊 幫我加個這個模型的預測公式 然後8.2的對話紀錄 請幫我完整寫出來 如果可以用（pdfCrowd 匯出）然後再貼上來 那就用這方法

第 11 輪 — Claude

4.3 的 k 對照表已刪除：作業未要求這張表，上方合併圖 (a)(b)(c) 已呈現 5 種方法在 k = 1–18 的完整曲線，「簡約性分析」也寫了關鍵數字，刪除不影響內容。在 4.5 加入主模型的預測公式（含 smearing 修正與 95% 預測區間的近似寫法），並以範例房屋驗證公式與程式結果一致。pdfCrowd 需要在瀏覽器裡開啟對話頁面才能匯出，Claude 無法代為操作，所以改為把完整對話原文直接寫進 8.2。

第 12 輪 — 學生

你有辦法弄出類似pdfCrowd 的效果嗎

第 12 輪 — Claude

做出來了：7115056079_hw2_Claude對話紀錄.pdf，共 10 頁，第 1–12 輪完整收錄。做法和 pdfCrowd 一樣：先把對話排成網頁，再用瀏覽器轉成 PDF。排版仿照聊天介面，你的訊息在右邊（藍色）、我的回覆在左邊（灰色），每則標了第幾輪；表格、清單、粗體都保留。頁首寫了報告標題、學號、對話期間和總輪數，頁尾有頁碼。

和真正 pdfCrowd 的差別：這份不是 pdfCrowd 網站產生的，而是用同樣原理（網頁轉 PDF）做的，頁首已經註明產生方式；只收錄對話文字，工具操作過程沒有列入；如果老師嚴格要求 pdfCrowd 本身的匯出檔，還是需要你在瀏覽器打開這次對話，自己用 pdfCrowd 轉一次。

第 13 輪 — 學生

你幫我確認下這份報告有缺少甚麼嗎或還需要補充甚麼嗎 若以這份頻紛表準來看 我能拿到幾分以下的都不用再放在報告裡（貼上作業的「三、評分標準」）

第 13 輪 — Claude

我對照了作業的「繳交內容」和評分標準，把報告、程式、對話紀錄逐項看過一遍。整體來說，必要項目都已經涵蓋，只剩兩件小事要處理。

評分項目	配分	預估
CRISP-DM 流程完整且邏輯清楚	25	23–25
包含 GPT 對話與 NotebookLM 摘要	15	12–15
資料集來源與研究脈絡	10	9–10
模型正確可執行，具特徵選擇與評估	25	24–25
結果合理、美觀、有說服力	15	13–15
Kaggle 名次／預測結果評估	10	9–10
合計	100	約 90–98

這只是我依評分標準做的估計。建議注意的地方：① ChatGPT 的對話要另外附上；② 8.1 裡「與本報告結果對照」那段不是 NotebookLM 寫的；③ 報告長度可以考慮縮短；④ GitHub／README 是選做。

第 14 輪 — 學生

這是他要繳交的東西（貼上作業的「5. 繳交內容」）沒有github 成是我等等用其他東西跑

第 14 輪 — Claude

7115056079_hw2.zip 已經打包好，可以上傳了。我也試過把它解壓到空資料夾，從頭跑一次程式，結果正常：16 張圖和 7 個結果檔都有產生，數字和報告一致。另外附了 README.md（執行說明）和 requirements.txt（套件清單），方便你換環境跑。在其他環境跑的注意事項：kc_house_data.csv 要和程式放在同一個資料夾；先執行 pip install -r requirements.txt；全部跑完大約 1 分鐘。

第 15 輪 — 學生

報告 PDF：GPT 對話過程 我改為跟你的對話紀錄了 所以應該不用 然後報告 PDF：GPT 對話過程 要額外給媽 應為我權把它弄進一個pdf黨了 還有我寫報告的順序對嗎

第 15 輪 — Claude

ChatGPT 對話不用另外附，沒問題；對話紀錄 PDF 不必另外附，作業要求的是「報告 PDF 裡要包含 GPT 對話過程」，報告已經放了完整對話原文。報告順序大致正確，建議微調一處：第 7 節「主流解法比較」引用的 [12]–[14] 正是 NotebookLM 研究的來源，建議改成「7 NotebookLM 研究摘要 → 8 主流與更優解法比較 → 9 GPT 對話過程」：先研究網路解法，再拿來和自己的結果比較；最長的對話紀錄放在最後當附錄。

第 16 輪 — 學生

要 然後聊天版 PDF 要移除 看你覺得需要在一開始寫個目錄嗎 或是 甚麼其他的方式可以一眼看清我有寫那些東西

第 16 輪 — Claude

已將章節調整為「7 NotebookLM 研究摘要 → 8 網路主流與更優解法比較 → 9 GPT 輔助內容」，內文中的章節引用一併更新；在第 1 頁摘要下方加入「報告導覽」，用一張表列出每章內容與對應的作業要求；壓縮檔移除聊天版 PDF，對話過程只保留在報告第 9 節。

9.2 AI 輔助範圍說明

項目	AI 輔助內容	本人工作
資料集	提供候選清單與條件檢查	決定使用 King County 房價資料集並下載
程式	撰寫分析程式並測試執行	提供資料、執行與檢查結果
報告	撰寫 CRISP-DM 各節初稿與圖表說明	審閱、修改與定稿
NotebookLM 摘要	由 NotebookLM 根據 3 篇研究來源 [12][13][14] 產生摘要（8.1）	挑選研究來源、向 NotebookLM 提問，並將摘要放入報告

參考資料

- [1] harlfoxem. *House Sales in King County, USA*. Kaggle. https://www.kaggle.com/datasets/harlfoxem/housesalesprediction
- [2] Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.
- [3] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2nd ed.). Springer.（線性回歸、信賴與預測區間、Best Subset 與 Forward Stepwise Selection）
- [4] Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B, 58*(1), 267–288.
- [5] Guyon, I., Weston, J., Barnhill, S., & Vapnik, V. (2002). Gene selection for cancer classification using support vector machines. *Machine Learning, 46*, 389–422.（RFE）
- [6] Zou, H., & Hastie, T. (2005). Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society: Series B, 67*(2), 301–320.
- [7] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

- [8] Duan, N. (1983). Smearing estimate: A nonparametric retransformation method. *Journal of the American Statistical Association, 78*(383), 605–610.
- [9] Durbin, J., & Watson, G. S. (1950). Testing for serial correlation in least squares regression I. *Biometrika, 37*(3/4), 409–428.
- [10] Jarque, C. M., & Bera, A. K. (1980). Efficient tests for normality, homoscedasticity and serial independence of regression residuals. *Economics Letters, 6*(3), 255–259.
- [11] Cook, R. D. (1977). Detection of influential observation in linear regression. *Technometrics, 19*(1), 15–18.
- [12] Ronotana, S. A. *Predicting Housing Prices Using Multiple Linear Regression*. RPubs. https://rpubs.com/staneaurelius/house_price_prediction
- [13] Weissmueller, N. *Winning Kaggle Solution: Predicting property sales prices*. RPubs. https://rpubs.com/nweissm/670674
- [14] Chandramouli, B. (2019). *Real-estate price prediction for King County region*. Stanford CS229 Project Report. https://cs229.stanford.edu/proj2019aut/data/assignment_308832_raw/26646708.pdf